

**LAPORAN UJIAN TENGAH SEMESTER (UTS)
MATA KULIAH *BUSINESS INTELLIGENCE*
PERANCANGAN DAN IMPLEMENTASI DATA
WAREHOUSE UNTUK ANALISIS DAN *FORECASTING*
PENJUALAN *RETAIL***



Disusun Oleh:

Nabila Imtiyaz Agustin	2409116011
Zahra Aulia Rahmah	2409116020
Aliyah Azzah Sekedang	2409116021

**PROGRAM STUDI SISTEM INFORMASI
FAKULTAS TEKNIK
UNIVERSITAS MULAWARMAN
2026**

DAFTAR ISI

DAFTAR ISI.....	2
DAFTAR GAMBAR.....	3
DAFTAR TABEL	4
BAB I PENDAHULUAN.....	5
1.1 Latar Belakang	5
1.2 Rumusan Masalah	5
1.3 Tujuan Penelitian	6
1.4 Manfaat Penelitian	6
BAB II PEMBAHASAN.....	7
2.1 Deskripsi Dataset Sales Forecasting Retail.....	7
2.2 Analisis Kebutuhan Data	7
2.3 Perancangan Data Warehouse.....	8
2.3.1 Arsitektur Sistem	9
2.3.2 Desain Star Schema	11
2.4 Proses ETL (Extract, Transform, Load)	12
2.4.1 Extract	12
2.4.2 Transform.....	12
2.4.3 Load	16
2.5 Visualisasi Data	17
2.6 Analisis Hasil Akhir Data	22
2.6.1 Analisis Tren Penjualan Berdasarkan Waktu	23
2.6.2 Analisis Performa Produk dan Kategori	23
2.6.3 Analisis Segmentasi dan Lokasi Pelanggan.....	23
2.6.4 Potensi Forecasting (Peramalan) Penjualan.....	24
BAB III PENUTUP	25
3.1 Kesimpulan	25
3.2 Saran	25
DAFTAR PUSTAKA.....	27

DAFTAR GAMBAR

Gambar 2. 1	Dataset Sales Forecasting Retail	7
Gambar 2. 2	Analisis Kebutuhan Data	8
Gambar 2. 3	Proses Pengecekan Dataset.....	9
Gambar 2. 4	Proses Pengecekan Data	10
Gambar 2. 5	Menghapus data duplikat.....	10
Gambar 2. 6	Mengubah format tanggal.....	10
Gambar 2. 7	Diagram Star Schema	11
Gambar 2. 8	Tahap Extract.....	12
Gambar 2. 9	Mengecek Missing Values	13
Gambar 2. 10	Menghapus data duplikat.....	13
Gambar 2. 11	Mengubah format tanggal.....	14
Gambar 2. 12	Membuat Tabel Dimensi Waktu (dim_date).....	14
Gambar 2. 13	Membuat Tabel Dimensi Produk (dim_product)	15
Gambar 2. 14	Membuat Tabel Dimensi Customer (dim_customer)	15
Gambar 2. 15	Membuat Tabel Dimensi Lokasi (dim_location)	15
Gambar 2. 16	Membuat Tabel Fakta (fact_sales)	16
Gambar 2. 17	Tahap Load.....	16
Gambar 2. 18	Source code tren penjualan per bulan.....	17
Gambar 2. 19	Visualisasi tren penjualan per bulan.....	18
Gambar 2. 20	Source code kontribusi penjualan berdasarkan kategori produk.....	18
Gambar 2. 21	Visualisasi kontribusi penjualan berdasarkan kategori produk	19
Gambar 2. 22	Source code top 10 produk dengan penjualan tertinggi	20
Gambar 2. 23	Visualisasi top 10 produk dengan penjualan tertinggi	20
Gambar 2. 24	Source code distribusi penjualan kategori dan segmen pelanggan	21
Gambar 2. 25	Visualisasi distribusi penjualan kategori dan segmen pelangga.....	21
Gambar 2. 26	Source code distribusi frekuensi transaksi per segmen pelanggan.....	22
Gambar 2. 27	Visualisasi distribusi frekuensi transaksi per segmen pelanggan.....	22

DAFTAR TABEL

BAB I

PENDAHULUAN

1.1 Latar Belakang

Dalam era digital saat ini, perusahaan retail menghasilkan data transaksi dalam jumlah besar setiap harinya. Data tersebut mencakup informasi mengenai tanggal transaksi, jumlah penjualan, produk yang terjual, serta lokasi toko. Volume data yang terus meningkat memerlukan sistem pengelolaan yang mampu menyimpan, mengintegrasikan, dan menganalisis data secara efektif untuk mendukung pengambilan keputusan strategis.

Salah satu solusi yang digunakan dalam pengelolaan data skala besar adalah Data Warehouse. Data Warehouse memungkinkan integrasi data dari berbagai sumber ke dalam satu sistem terstruktur yang dirancang khusus untuk kebutuhan analisis dan pelaporan. Dengan struktur seperti star schema, data dapat diorganisasikan ke dalam tabel fakta dan tabel dimensi sehingga memudahkan proses analisis multidimensi.

Dataset *Sales Forecasting (Retail)* yang digunakan dalam penelitian ini berisi data historis penjualan dari beberapa toko dan item dalam rentang waktu tertentu. Dataset ini memiliki atribut utama seperti tanggal, store, item, dan jumlah penjualan (*sales*). Data tersebut sangat relevan untuk dianalisis guna mengetahui pola tren penjualan, performa produk, serta potensi peramalan (*forecasting*) di masa mendatang.

Oleh karena itu, pada proyek ini dilakukan perancangan dan implementasi Data Warehouse berbasis star schema untuk mengolah dataset penjualan retail tersebut. Hasil implementasi diharapkan dapat mendukung analisis tren penjualan dan memberikan insight yang bermanfaat bagi pengambilan keputusan bisnis.

1.2 Rumusan Masalah

Berdasarkan latar belakang yang telah dijelaskan, maka rumusan masalah dalam proyek ini yaitu,

1. Bagaimana merancang dan membangun Data Warehouse berbasis star schema menggunakan dataset *Sales Forecasting (Retail)*?
2. Bagaimana proses ETL (*Extract, Transform, Load*) dilakukan untuk mengintegrasikan data mentah ke dalam Data Warehouse?
3. Bagaimana Data Warehouse yang dibangun dapat digunakan untuk menganalisis tren penjualan berdasarkan waktu, toko, dan item?
4. *Insight* apa saja yang dapat diperoleh dari hasil analisis data penjualan retail tersebut?

1.3 Tujuan Penelitian

Adapun tujuan dari proyek ini yaitu,

1. Merancang struktur Data Warehouse menggunakan pendekatan star schema.
2. Mengimplementasikan proses ETL dari dataset mentah ke dalam tabel fakta dan tabel dimensi.
3. Menghasilkan sistem penyimpanan data yang terstruktur dan siap digunakan untuk analisis multidimensi.
4. Melakukan analisis data untuk mengetahui pola dan tren penjualan retail.
5. Memberikan insight yang dapat mendukung pengambilan keputusan bisnis.

1.4 Manfaat Penelitian

Manfaat yang diharapkan dari proyek ini yaitu,

1. Membantu perusahaan retail dalam memahami pola penjualan berdasarkan waktu, toko, dan produk.
2. Menyediakan struktur data yang terorganisir untuk mendukung analisis dan *forecasting*.
3. Menjadi referensi implementasi Data Warehouse dalam bidang *Business Intelligence*.
4. Memberikan pengalaman praktis dalam membangun Data Warehouse dan melakukan analisis data.

BAB II

PEMBAHASAN

2.1 Deskripsi Dataset Sales Forecasting Retail

Dataset yang digunakan dalam penelitian ini adalah dataset Sales Forecasting Retail yang diperoleh dari platform Kaggle. Dataset tersebut berisi data historis transaksi penjualan yang mencakup berbagai informasi penting seperti pelanggan, produk, kategori, wilayah, dan jumlah penjualan. Dataset ini digunakan sebagai sumber data utama dalam proses pembangunan Data Warehouse dan analisis *Business Intelligence*.

Dataset disimpan dalam format CSV dan dibaca menggunakan bahasa pemrograman Python dengan bantuan library Pandas. Proses pembacaan dataset dilakukan menggunakan fungsi `pd.read_csv()` untuk memuat data ke dalam dataframe sehingga dapat dilakukan proses pengolahan data pada tahap selanjutnya.

import pandas as pd

df = pd.read_csv('content/drive/MyDrive/Tugas BI/train.csv')

df

Row ID	Order ID	Order Date	Ship Date	Ship Mode	Customer ID	Customer Name	Segment	Country	City	State	Postal Code	Region	Product ID	Category	Sub-Category	Product Name	Sales	
0	1	CA-2017-152156	08/11/2017	11/11/2017	Second Class	CG-12520	Claire Gula	Consumer	United States	Henderson	Kentucky	42420.0	South	FUR-BO-10001798	Furniture	Bookcases	Bush Somerset Collection Bookcase	201.9600
1	2	CA-2017-152156	08/11/2017	11/11/2017	Second Class	CG-12520	Claire Gula	Consumer	United States	Henderson	Kentucky	42420.0	South	FUR-CH-10000454	Furniture	Chairs	Hon Deluxe Fabric Upholstered Stacking Chairs...	731.9400
2	3	CA-2017-138988	12/06/2017	19/06/2017	Second Class	DV-13045	Darrin Van Huff	Corporate	United States	Los Angeles	California	90036.0	West	OFF-LA-10000240	Office Supplies	Labels	Self-Adhesive Address Labels for Typewriters b...	14.6200
3	4	US-2016-108996	11/10/2016	18/10/2016	Standard Class	SO-20335	Sean O'Donnell	Consumer	United States	Fort Lauderdale	Florida	33311.0	South	FUR-TA-10000577	Furniture	Tables	Bretford CR4500 Series Slim Rectangular Table	957.5775
4	5	US-2016-108996	11/10/2016	18/10/2016	Standard Class	SO-20335	Sean O'Donnell	Consumer	United States	Fort Lauderdale	Florida	33311.0	South	OFF-ST-10000760	Office Supplies	Storage	Eldon Fold 'N Roll Cart System	22.3680
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...
9795	9796	CA-2017-125920	21/05/2017	28/05/2017	Standard Class	SH-19075	Sally Hughshy	Corporate	United States	Chicago	Illinois	60610.0	Central	OFF-BI-10003429	Office Supplies	Binders	Cardinal HOLDIT Binder Insert Strips,Extra St...	3.7080
9796	9797	CA-2016-128908	12/01/2016	17/01/2016	Standard Class	CS-12490	Cindy Schnelling	Corporate	United States	Toledo	Ohio	43615.0	East	OFF-AR-10001374	Office Supplies	Art	BIC Brite Liner Highlighters, Chisel Tip	10.3680
9797	9798	CA-2016-128908	12/01/2016	17/01/2016	Standard Class	CS-12490	Cindy Schnelling	Corporate	United States	Toledo	Ohio	43615.0	East	TEC-PH-10004977	Technology	Phones	GE 30524EE4	235.1880
9798	9799	CA-2016-128908	12/01/2016	17/01/2016	Standard Class	CS-12490	Cindy Schnelling	Corporate	United States	Toledo	Ohio	43615.0	East	TEC-PH-10000912	Technology	Phones	Anker 24W Portable Micro USB Car Charger	28.3760
9799	9800	CA-2016-128908	12/01/2016	17/01/2016	Standard Class	CS-12490	Cindy Schnelling	Corporate	United States	Toledo	Ohio	43615.0	East	TEC-AC-10000487	Technology	Accessories	SanDisk Cruiser 4 GB USB Flash Drive	10.3840

9800 rows x 18 columns

Gambar 2. 1 Dataset Sales Forecasting Retail

Berdasarkan gambar di atas, dataset berhasil dimuat ke dalam sistem dengan jumlah data sebanyak 9800 baris dan 18 kolom. Dataset tersebut berisi informasi transaksi penjualan yang meliputi atribut seperti Order ID, Order Date, Ship Mode, Customer Name, Product Name, Category, Region, dan Sales.


Data yang telah dimuat ini menjadi dasar dalam proses analisis dan pembangunan Data Warehouse. Selanjutnya data akan diperiksa struktur dan kualitasnya melalui proses analisis kebutuhan data sebelum dilakukan proses transformasi dan penyimpanan data ke dalam tabel dimensi dan tabel fakta.

2.2 Analisis Kebutuhan Data

Pada tahap analisis kebutuhan data, dilakukan pemeriksaan terhadap struktur dataset yang digunakan dalam penelitian. Pemeriksaan ini bertujuan untuk mengetahui jumlah data, jumlah kolom, serta tipe data pada setiap atribut yang terdapat dalam dataset. Proses ini penting dilakukan untuk memahami kondisi awal data sebelum dilakukan proses pembersihan dan transformasi data.

Untuk menampilkan informasi mengenai struktur dataset, digunakan fungsi `df.info()` pada library Pandas. Fungsi ini digunakan untuk melihat ringkasan informasi dataset seperti

jumlah baris data, nama kolom, tipe data, serta jumlah data yang tidak kosong pada setiap kolom.



3. Menampilkan Informasi Tentang Dataset

```
print(df.info())
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 9800 entries, 0 to 9799
Data columns (total 18 columns):
 #   Column              Non-Null Count  Dtype  
---  --
 0   Row ID              9800 non-null  int64  
 1   Order ID            9800 non-null  object  
 2   Order Date          9800 non-null  object  
 3   Ship Date           9800 non-null  object  
 4   Ship Mode            9800 non-null  object  
 5   Customer ID         9800 non-null  object  
 6   Customer Name       9800 non-null  object  
 7   Segment             9800 non-null  object  
 8   Country             9800 non-null  object  
 9   City                9800 non-null  object  
10   State               9800 non-null  object  
11   Postal Code         9789 non-null  float64 
12   Region              9800 non-null  object  
13   Product ID          9800 non-null  object  
14   Category            9800 non-null  object  
15   Sub-Category        9800 non-null  object  
16   Product Name        9800 non-null  object  
17   Sales               9800 non-null  float64 
dtypes: float64(2), int64(1), object(15)
memory usage: 1.3+ MB
None
```

Tahap ini dilakukan untuk mengetahui struktur dataset seperti jumlah baris dan kolom, nama kolom, serta tipe data pada setiap atribut. Informasi ini penting untuk memahami kondisi awal data sebelum dilakukan proses pembersihan data.

Gambar 2. 2 Analisis Kebutuhan Data

Berdasarkan hasil pemeriksaan struktur dataset pada gambar di atas, diketahui bahwa dataset memiliki jumlah data sebanyak 9800 baris dan 18 kolom. Setiap kolom memiliki tipe data yang berbeda, seperti integer (int64), object, dan float (float64). Sebagian besar kolom memiliki jumlah data yang lengkap tanpa nilai kosong.

Informasi ini sangat penting dalam proses pembangunan Data Warehouse karena membantu dalam menentukan langkah selanjutnya dalam proses ETL, seperti pembersihan data, konversi tipe data, dan pembuatan tabel dimensi serta tabel fakta.

2.3 Perancangan Data Warehouse

Pada tahap ini dilakukan proses perancangan Data Warehouse yang bertujuan untuk mengintegrasikan data penjualan retail ke dalam suatu yang terstruktur dan siap digunakan untuk analisis. Perancangan Data Warehouse merupakan salah satu tahapan penting dalam Business Intelligence karena menentukan bagaimana data akan disimpan, diorganisasikan, serta diakses untuk menghasilkan informasi yang bernilai.

Dataset yang digunakan pada penelitian ini awalnya berupa data mentah yang tersimpan dalam format CSV dan belum memiliki struktur yang sesuai untuk kebutuhan analisis. Oleh karena itu, diperlukan suatu proses perancangan agar data dapat diubah menjadi bentuk yang lebih terstruktur melalui pendekatan Data Warehouse.

Dalam penelitian ini, perancangan Data Warehouse dilakukan dengan menggunakan pendekatan star schema. Pendekatan ini dipilih karena memiliki struktur yang sederhana, mudah dipahami serta mampu meningkatkan performa dalam proses query dan analisis data. Pada model ini, data dibagi menjadi dua bagian utama, yaitu tabel fakta dan tabel dimensi.

Tabel fakta berfungsi sebagai pusat penyimpanan data transaksi yang bersifat kuantitatif, seperti jumlah penjualan. Sedangkan tabel dimensi berfungsi untuk menyimpan informasi deskriptif yang memberikan konteks terhadap data transaksi, seperti waktu, produk, pelanggan, dan lokasi.

Selain itu, dalam perancangan ini juga dilakukan identifikasi terhadap kebutuhan analisis yang dilakukan, seperti analisis tren penjualan berdasarkan waktu, analisis performa produk, serta distribusi penjualan berdasarkan wilayah. Dengan demikian, struktur Data Warehouse yang dirancang dapat mendukung berbagai kebutuhan analisis secara efektif dan efisien.

2.3.1 Arsitektur Sistem

Arsitektur sistem dalam pembangunan Data Warehouse pada penelitian ini dirancang dengan mengacu pada konsep ETL (Extract, Transform, Load), yang merupakan proses utama dalam pengolahan data pada sistem Business Intelligence. Arsitektur ini menggambarkan alur bagaimana data mentah diambil, diproses, hingga akhirnya disimpan dalam bentuk yang siap untuk dianalisis.

Tahap pertama dalam arsitektur sistem adalah Extract, yaitu proses pengambilan data dari sumber data. Dalam penelitian ini, data diambil dari dataset Sales Forecasting Retail yang disimpan dalam format CSV. Proses ini dilakukan menggunakan bahasa pemrograman Python dengan bantuan library Pandas. Dataset dibaca menggunakan fungsi `pd.read_csv()` dan dimuat ke dalam dataframe untuk selanjutnya diproses. Kode di bawah ini digunakan untuk membaca file dataset ke dalam dataframe. Dataframe ini menjadi sumber dalam seluruh proses pengolahan data pada penelitian ini.

```
print(df.head())
```

...	Row ID	Order ID	Order Date	Ship Date	Ship Mode	Customer ID	\
0	1	CA-2017-152156	08/11/2017	11/11/2017	Second Class	CG-12520	
1	2	CA-2017-152156	08/11/2017	11/11/2017	Second Class	CG-12520	
2	3	CA-2017-138688	12/06/2017	16/06/2017	Second Class	DV-13045	
3	4	US-2016-108966	11/10/2016	18/10/2016	Standard Class	SO-20335	
4	5	US-2016-108966	11/10/2016	18/10/2016	Standard Class	SO-20335	

	Customer Name	Segment	Country	City	State	\
0	Claire Gute	Consumer	United States	Henderson	Kentucky	
1	Claire Gute	Consumer	United States	Henderson	Kentucky	
2	Darrin Van Huff	Corporate	United States	Los Angeles	California	
3	Sean O'Donnell	Consumer	United States	Fort Lauderdale	Florida	
4	Sean O'Donnell	Consumer	United States	Fort Lauderdale	Florida	

	Postal Code	Region	Product ID	Category	Sub-Category	\
0	42420.0	South	FUR-B0-10001798	Furniture	Bookcases	
1	42420.0	South	FUR-CH-10000454	Furniture	Chairs	
2	90036.0	West	OFF-LA-10000240	Office Supplies	Labels	
3	33311.0	South	FUR-TA-10000577	Furniture	Tables	
4	33311.0	South	OFF-ST-10000760	Office Supplies	Storage	

	Product Name	Sales
0	Bush Somerset Collection Bookcase	261.9600
1	Hon Deluxe Fabric Upholstered Stacking Chairs,...	731.9400
2	Self-Adhesive Address Labels for Typewriters b...	14.6200
3	Bretford CR4500 Series Slim Rectangular Table	957.5775
4	Eldon Fold 'N Roll Cart System	22.3680

Gambar 2. 3 Proses Pengecekan Dataset

Tahap berikutnya adalah Transform, yaitu proses pengolahan data untuk meningkatkan kualitas serta menyesuaikan struktur data agar sesuai dengan kebutuhan Data Warehouse. Pada tahap ini dilakukan beberapa proses penting seperti pemeriksaan struktur data, pengecekan nilai kosong (missing values), penghapusan data duplikat, serta konversi tipe data.

Row ID	0
Order ID	0
Order Date	0
Ship Date	0
Ship Mode	0
Customer ID	0
Customer Name	0
Segment	0
Country	0
City	0
State	0
Postal Code	11
Region	0
Product ID	0
Category	0
Sub-Category	0
Product Name	0
Sales	0

dtype: int64

Gambar 2. 4 Proses Pengecekan Data

6. Menghapus Data Duplikat
<code>df = df.drop_duplicates()</code>

Gambar 2. 5 Menghapus data duplikat

8. Mengubah Format Tanggal
<pre>df['order date'] = pd.to_datetime(df['order date'], dayfirst=True) df['ship date'] = pd.to_datetime(df['ship date'], dayfirst=True)</pre>

Gambar 2. 6 Mengubah format tanggal

Penjelasan:

- `df.info()` digunakan untuk melihat struktur dataset
- `df.isnull().sum()` digunakan untuk mengecek jumlah data kosong
- `drop_duplicates()` digunakan untuk menghapus data yang sama
- `to_datetime()` digunakan untuk mengubah format tanggal agar dapat digunakan dalam analisis berbasis waktu


Tahap terakhir adalah Load, yaitu proses penyimpanan data yang telah melalui proses transformasi ke dalam bentuk tabel yang terstruktur. Dalam penelitian ini, data disimpan dalam bentuk file CSV yang merepresentasikan tabel dimensi dan tabel fakta.

Kode Load: `df.to_csv("clean_data.csv", index=False)`. Kode tersebut digunakan untuk menyimpan data yang telah dibersihkan sehingga dapat digunakan pada tahap selanjutnya dalam pembuatan tabel dimensi dan tabel fakta.

Dengan adanya arsitektur sistem ini, proses pengolahan data menjadi lebih terstruktur, sistematis, dan mudah dipahami. Setiap tahap memiliki peran penting dalam memastikan bahwa data yang digunakan dalam analisis memiliki kualitas yang baik.

2.3.2 Desain Star Schema

Desain Data Warehouse pada penelitian ini menggunakan model **star schema**, yaitu struktur basis data yang terdiri dari satu tabel fakta sebagai pusat dan beberapa tabel dimensi yang terhubung langsung ke tabel fakta tersebut. Model ini dipilih karena memiliki keunggulan dalam kemudahan pemahaman, efisiensi query, serta performa yang baik dalam proses analisis data.



Gambar 2. 7 Diagram Star Schema

Pada diagram yang ditampilkan, tabel *fact_sales* berperan sebagai tabel utama yang menyimpan data transaksi penjualan. Tabel ini berisi atribut kuantitatif berupa nilai penjualan (*sales*) serta beberapa atribut kunci (*key*) yang menghubungkan ke tabel dimensi, yaitu *date_key*, *product_key*, *customer_key*, dan *location_key*. Setiap baris pada tabel fakta merepresentasikan satu transaksi penjualan.

Tabel dimensi digunakan untuk menyimpan informasi deskriptif terhadap data pada tabel fakta, yang terdiri dari:

- *dim_date*, yang menyimpan informasi waktu seperti tanggal lengkap, hari, bulan, tahun, dan kuartal. Tabel ini digunakan untuk analisis tren penjualan berdasarkan waktu.
- *dim_product*, yang berisi informasi produk seperti nama produk, kategori, dan

sub-kategori. Tabel ini mendukung analisis performa produk dan kategori.

- `dim_customer`, yang menyimpan data pelanggan seperti nama pelanggan dan segmentasi, sehingga memungkinkan analisis berdasarkan perilaku dan segmen pelanggan.
- `dim_location`, yang berisi informasi lokasi seperti negara, wilayah (region), dan kota, yang digunakan untuk analisis distribusi penjualan berdasarkan wilayah geografis.

Relasi antara tabel dimensi dan tabel fakta bersifat one-to-many (1:N), di mana satu data pada tabel dimensi dapat berhubungan dengan banyak data pada tabel fakta. Sebagai contoh, satu produk pada tabel *dim_product* dapat muncul pada banyak transaksi di tabel *fact_sales*. Relasi ini diimplementasikan melalui penggunaan *foreign key* pada tabel fakta yang mengacu pada *primary key* di masing-masing tabel dimensi.

2.4 Proses ETL (Extract, Transform, Load)

2.4.1 Extract

Pada tahap Extract, data diambil dari sumber data utama yaitu dataset Sales Forecasting Retail yang disimpan dalam format CSV. Proses pengambilan data dilakukan menggunakan bahasa pemrograman Python dengan bantuan library Pandas. Fungsi yang digunakan untuk membaca dataset adalah `pd.read_csv()`. Tahap Extract merupakan langkah awal dalam proses ETL yang bertujuan untuk mengambil data mentah dari sumber data sehingga dapat diproses pada tahap berikutnya.

df = pd.read_csv('content/drive/MyDrive/Tugas 82/train.csv')

df

Row ID	Order ID	Order Date	Ship Date	Ship Mode	Customer ID	Customer Name	Segment	Country	City	State	Postal Code	Region	Product ID	Category	Sub-Category	Product Name	Sales	
0	1	CA-2017-152156	08/11/2017	11/11/2017	Second Class	CG-12520	Claire Gule	Consumer	United States	Henderson	Kentucky	42420.0	South	FUR-BO-10001798	Furniture	Bookcases	Bush Somerset Collection Bookcase	261.9500
1	2	CA-2017-152156	08/11/2017	11/11/2017	Second Class	CG-12520	Claire Gule	Consumer	United States	Henderson	Kentucky	42420.0	South	FUR-CH-10000454	Furniture	Chairs	Hon Deluxe Fabric Upholstered Stacking Chairs...	731.9400
2	3	CA-2017-138888	12/09/2017	16/09/2017	Second Class	DV-13045	Darin Van Huff	Corporate	United States	Los Angeles	California	90038.0	West	OFF-LA-10000240	Office Supplies	Labels	Self-Adhesive Address Labels for Typewriters B...	14.6200
3	4	US-2016-108995	11/10/2016	18/10/2016	Standard Class	SO-20335	Sean O'Donnell	Consumer	United States	Fort Lauderdale	Florida	33311.0	South	FUR-TA-10000577	Furniture	Tables	Brexford CR4500 Series Slim Rectangular Table	957.5775
4	5	US-2016-108995	11/10/2016	18/10/2016	Standard Class	SO-20335	Sean O'Donnell	Consumer	United States	Fort Lauderdale	Florida	33311.0	South	OFF-ST-10000780	Office Supplies	Storage	Eldon Fold 'N Roll Cart System	22.3680
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...
9795	9795	CA-2017-125920	21/05/2017	28/05/2017	Standard Class	SH-19975	Sally Hugbary	Corporate	United States	Chicago	Illinois	60610.0	Central	OFF-BI-10003429	Office Supplies	Binders	Cardinal HOLDB! Binder Insert Strips, Extra St...	3.7960
9796	9797	CA-2016-128608	12/01/2016	17/01/2016	Standard Class	CS-12490	Cindy Schmelling	Corporate	United States	Toledo	Ohio	43615.0	East	OFF-AR-10001374	Office Supplies	Art	BIC Brite Liner Highlighters, Chisel Tip	10.3680
9797	9796	CA-2016-128608	12/01/2016	17/01/2016	Standard Class	CS-12490	Cindy Schmelling	Corporate	United States	Toledo	Ohio	43615.0	East	TEC-PH-10004977	Technology	Phones	GE 30524EE4	235.1880
9798	9796	CA-2016-128608	12/01/2016	17/01/2016	Standard Class	CS-12490	Cindy Schmelling	Corporate	United States	Toledo	Ohio	43615.0	East	TEC-PH-10000912	Technology	Phones	Anker 24W Portable Micro USB Car Charger	26.3760
9799	9800	CA-2016-128608	12/01/2016	17/01/2016	Standard Class	CS-12490	Cindy Schmelling	Corporate	United States	Toledo	Ohio	43615.0	East	TEC-AC-10000487	Technology	Accessories	SanDisk Cruiser 4 GB USB Flash Drive	10.3840

9800 rows x 18 columns

Gambar 2. 8 Tahap Extract


Berdasarkan gambar di atas, dataset berhasil diambil dari sumber data dan dimuat ke dalam sistem menggunakan fungsi `pd.read_csv()`. Dataset yang digunakan memiliki jumlah data sebanyak 9800 baris dan 18 kolom yang berisi informasi mengenai transaksi penjualan seperti pelanggan, produk, wilayah, kategori, dan jumlah penjualan.

Data yang telah berhasil diambil kemudian akan diproses pada tahap Transform untuk dilakukan pembersihan dan penyesuaian struktur data.

2.4.2 Transform

1. Mengecek Missing Values

Pada tahap Transform, dilakukan proses pemeriksaan data untuk mengetahui apakah terdapat data yang kosong atau missing values pada dataset. Pemeriksaan ini penting dilakukan untuk memastikan kualitas data sebelum digunakan dalam proses analisis. Untuk mengecek data kosong, digunakan fungsi `df.isnull().sum()` yang berfungsi untuk menghitung jumlah nilai kosong pada setiap kolom dalam dataset.



	0
Row ID	0
Order ID	0
Order Date	0
Ship Date	0
Ship Mode	0
Customer ID	0
Customer Name	0
Segment	0
Country	0
City	0
State	0
Postal Code	11
Region	0
Product ID	0
Category	0
Sub-Category	0
Product Name	0
Sales	0

dtype: int64

Gambar 2. 9 Mengecek Missing Values

Berdasarkan hasil pemeriksaan pada gambar di atas, diketahui bahwa sebagian besar kolom dalam dataset tidak memiliki nilai kosong. Namun, terdapat beberapa nilai kosong pada kolom Postal Code. Secara umum, dataset memiliki kualitas data yang baik sehingga dapat digunakan untuk proses transformasi data selanjutnya.

2. Menghapus Data Duplikat

Selain memeriksa missing values, pada tahap Transform juga dilakukan proses penghapusan data duplikat. Data duplikat merupakan data yang memiliki nilai yang sama pada seluruh atribut sehingga dapat menyebabkan hasil analisis menjadi tidak akurat. Untuk menghapus data duplikat, digunakan fungsi `drop_duplicates()` pada library Pandas.

```
df = df.drop_duplicates()
```

Gambar 2. 10 Menghapus data duplikat

Berdasarkan proses pada gambar di atas, data duplikat berhasil dihapus dari dataset menggunakan fungsi `drop_duplicates()`. Proses ini bertujuan untuk

memastikan bahwa setiap data transaksi yang digunakan dalam analisis adalah data yang unik dan tidak terjadi pengulangan data.

3. Mengubah Format Tanggal

Pada tahap Transform, dilakukan proses konversi tipe data pada kolom tanggal. Kolom order date dan ship date awalnya memiliki tipe data object sehingga perlu diubah menjadi tipe data datetime agar dapat digunakan dalam analisis waktu.

```
df['order date'] = pd.to_datetime(df['order date'], dayfirst=True)
df['ship date'] = pd.to_datetime(df['ship date'], dayfirst=True)
```

Gambar 2. 11 Mengubah format tanggal

Berdasarkan proses pada gambar di atas, kolom order date dan ship date berhasil dikonversi menjadi tipe data datetime menggunakan fungsi `pd.to_datetime()`. Dengan perubahan ini, data dapat digunakan untuk analisis berdasarkan waktu seperti analisis bulanan, tahunan, dan kuartal.

4. Membuat Tabel Dimensi Waktu (dim_date)

Setelah data tanggal berhasil dikonversi, langkah selanjutnya adalah membuat tabel dimensi waktu (dim_date). Tabel ini digunakan untuk menyimpan informasi waktu yang akan digunakan dalam analisis data berdasarkan periode tertentu. Informasi waktu yang disimpan meliputi tanggal, hari, bulan, tahun, dan kuartal.

```
dim_date = df[['order date', 'day', 'month', 'year', 'quarter']].drop_duplicates()

dim_date.to_csv("dim_date.csv", index=False)
```

Gambar 2. 12 Membuat Tabel Dimensi Waktu (dim_date)

Berdasarkan proses pada gambar di atas, tabel dimensi waktu (dim_date) berhasil dibuat dari dataset utama. Tabel ini berisi informasi tanggal yang telah dipisahkan menjadi beberapa atribut waktu seperti hari, bulan, tahun, dan kuartal. Data kemudian disimpan dalam format CSV untuk digunakan dalam sistem Data Warehouse.

5. Membuat Tabel Dimensi Produk (dim_product)

Pada tahap Transform, dilakukan pembuatan tabel dimensi produk (dim_product). Tabel ini digunakan untuk menyimpan informasi mengenai produk yang terdapat dalam dataset. Informasi yang disimpan dalam tabel dimensi produk meliputi ID produk, nama produk, kategori produk, dan sub-kategori produk.

```
dim_product = df[
    ['product id', 'product name', 'category', 'sub-category']
].drop_duplicates()

dim_product.to_csv("dim_product.csv", index=False)
```

Gambar 2. 13 Membuat Tabel Dimensi Produk (dim_product)

Berdasarkan proses pada gambar di atas, tabel dimensi produk (dim_product) berhasil dibuat dari dataset utama. Tabel ini berisi informasi lengkap mengenai produk yang digunakan dalam analisis penjualan. Data kemudian disimpan dalam format CSV untuk digunakan dalam sistem Data Warehouse.

6. Membuat Tabel Dimensi Customer (dim_customer)

Pada tahap Transform, dilakukan pembuatan tabel dimensi pelanggan (dim_customer). Tabel ini digunakan untuk menyimpan informasi mengenai pelanggan yang melakukan transaksi penjualan. Informasi yang disimpan meliputi ID pelanggan, nama pelanggan, dan segmen pelanggan.

```
dim_customer = df[
    ['customer id', 'customer name', 'segment']
].drop_duplicates()

dim_customer.to_csv("dim_customer.csv", index=False)
```

Gambar 2. 14 Membuat Tabel Dimensi Customer (dim_customer)

Berdasarkan proses pada gambar di atas, tabel dimensi pelanggan (dim_customer) berhasil dibuat dari dataset utama. Tabel ini berisi informasi mengenai pelanggan dan segmen pelanggan yang digunakan dalam analisis penjualan. Data kemudian disimpan dalam format CSV untuk digunakan dalam sistem Data Warehouse.

7. Membuat Tabel Dimensi Lokasi (dim_location)

Pada tahap Transform, dilakukan pembuatan tabel dimensi lokasi (dim_location). Tabel ini digunakan untuk menyimpan informasi mengenai lokasi transaksi penjualan. Informasi yang disimpan meliputi negara, kota, negara bagian, dan region.

```
dim_location = df[
    ['country', 'city', 'state', 'region']
].drop_duplicates()

dim_location.to_csv("dim_location.csv", index=False)
```

Gambar 2. 15 Membuat Tabel Dimensi Lokasi (dim_location)

Berdasarkan proses pada gambar di atas, tabel dimensi lokasi (dim_location) berhasil dibuat dari dataset utama. Tabel ini berisi informasi

wilayah yang digunakan dalam analisis penjualan berdasarkan lokasi. Data kemudian disimpan dalam format CSV untuk digunakan dalam sistem Data Warehouse.

8. Membuat Tabel Fakta (fact_sales)

Langkah terakhir pada tahap Transform adalah membuat tabel fakta (fact_sales). Tabel ini merupakan tabel utama dalam Data Warehouse yang berisi data transaksi penjualan. Tabel fakta digunakan sebagai pusat analisis karena berisi informasi utama seperti ID pesanan, tanggal pesanan, pelanggan, produk, dan jumlah penjualan.

```
fact_sales = df[
    ['order id', 'order date', 'customer id', 'product id', 'sales']
]

fact_sales.to_csv("fact_sales.csv", index=False)
```

Gambar 2. 16 Membuat Tabel Fakta (fact_sales)

Berdasarkan proses pada gambar di atas, tabel fakta (fact_sales) berhasil dibuat dari dataset utama. Tabel ini berisi data transaksi penjualan yang akan digunakan sebagai sumber utama dalam proses analisis data pada sistem Business Intelligence. Data kemudian disimpan dalam format CSV untuk digunakan dalam sistem database atau aplikasi analisis data.

2.4.3 Load

Pada tahap Load, data yang telah melalui proses pembersihan dan transformasi kemudian disimpan ke dalam tabel dimensi dan tabel fakta sebagai bagian dari sistem Data Warehouse. Tahap ini merupakan langkah terakhir dalam proses ETL yang bertujuan untuk menyiapkan data agar dapat digunakan dalam sistem database atau analisis data. Dalam penelitian ini, tabel dimensi dan tabel fakta disimpan dalam format CSV menggunakan bahasa pemrograman Python. Proses penyimpanan data dilakukan setelah struktur tabel dimensi dan tabel fakta berhasil dibuat dari dataset yang telah diproses sebelumnya.

```
from google.colab import files

files.download("dim_date.csv")
files.download("dim_product.csv")
files.download("dim_customer.csv")
files.download("dim_location.csv")
files.download("fact_sales.csv")

...
```

Gambar 2. 17 Tahap Load

Berdasarkan gambar di atas, tabel dimensi dan tabel fakta berhasil disimpan dan diunduh dalam format CSV menggunakan fungsi `files.download()` pada Google Colab.

Tabel yang dihasilkan terdiri dari tabel dimensi waktu (*dim_date*), tabel dimensi produk (*dim_product*), tabel dimensi pelanggan (*dim_customer*), tabel dimensi lokasi (*dim_location*), serta tabel fakta penjualan (*fact_sales*). Data yang telah disimpan ini selanjutnya dapat digunakan dalam sistem database atau aplikasi Business Intelligence untuk proses analisis data dan pembuatan visualisasi.

2.5 Visualisasi Data

Visualisasi data merupakan tahap penting dalam proses Business Intelligence karena berfungsi untuk menyajikan hasil analisis data dalam bentuk yang lebih mudah dipahami. Pada penelitian ini, visualisasi dilakukan menggunakan Google Colab dengan bantuan library Python seperti *Matplotlib* dan *Seaborn*. Data yang digunakan berasal dari tabel fakta dan tabel dimensi yang telah dibangun pada Data Warehouse.

Melalui visualisasi, pola dan tren penjualan dapat diamati secara lebih jelas sehingga memudahkan dalam proses pengambilan keputusan. Beberapa visualisasi yang dihasilkan dalam penelitian ini antara lain:

1. Grafik Tren Penjualan per Bulan


```
import matplotlib.pyplot as plt
import seaborn as sns

# Persiapan data: Mengurutkan berdasarkan tahun dan bulan
monthly_sales = master_df.groupby(['year', 'month'])['sales'].sum().reset_index()
monthly_sales = monthly_sales.sort_values(['year', 'month'])

# Membuat label periode (format: YYYY-MM)
monthly_sales['period'] = monthly_sales['year'].astype(str) + '-' + monthly_sales['month'].astype(str).str.zfill(2)

plt.figure(figsize=(15, 6))
sns.lineplot(data=monthly_sales, x='period', y='sales', marker='o', linewidth=2.5)
plt.title('Tren Penjualan Bulanan (Total Sales)', fontsize=14)
plt.xticks(rotation=45)
plt.xlabel('Periode (Tahun-Bulan)')
plt.ylabel('Total Penjualan')
plt.grid(True, linestyle='--', alpha=0.6)
plt.show()
```

Gambar 2. 18 Source code tren penjualan per bulan



Gambar 2. 19 Visualisasi tren penjualan per bulan

Visualisasi pertama bertujuan untuk menganalisis tren penjualan berdasarkan waktu, khususnya dalam skala bulanan. Data terlebih dahulu dikelompokkan (*grouping*) berdasarkan atribut *year* dan *month*, kemudian dilakukan agregasi dengan menjumlahkan nilai *sales* untuk setiap periode.

Setelah itu, data diurutkan berdasarkan tahun dan bulan agar membentuk urutan kronologis. Dibat pula kolom tambahan berupa *period* dengan format “YYYY-MM” untuk memudahkan pembacaan pada sumbu horizontal.

Visualisasi ditampilkan dalam bentuk grafik garis (line chart) menggunakan library Seaborn. Grafik ini menunjukkan fluktuasi penjualan dari waktu ke waktu, sehingga dapat digunakan untuk mengidentifikasi pola tren, seperti kenaikan atau penurunan penjualan pada periode tertentu.


2. Grafik Kontribusi Penjualan Berdasarkan Kategori Produk

```
# Menghitung total penjualan per kategori
category_sales = master_df.groupby('category')['sales'].sum().sort_values(ascending=False)

plt.figure(figsize=(8, 8))
plt.pie(category_sales,
        labels=category_sales.index,
        autopct='%1.1f%%',
        startangle=140,
        colors=sns.color_palette('mako', len(category_sales)),
        explode=[0.05] * len(category_sales)) # Memberikan sedikit jarak antar potongan

plt.title('Persentase Kontribusi Penjualan per Kategori', fontsize=14)
plt.show()
```

Gambar 2. 20 Source code kontribusi penjualan berdasarkan kategori produk



Gambar 2. 21 Visualisasi kontribusi penjualan berdasarkan kategori produk

Visualisasi ini bertujuan untuk mengetahui kontribusi masing-masing kategori produk terhadap total penjualan. Data dikelompokkan berdasarkan atribut *category*, kemudian dilakukan penjumlahan nilai *sales* untuk setiap kategori.

Hasil agregasi tersebut divisualisasikan menggunakan diagram lingkaran (pie chart). Setiap bagian dari diagram menunjukkan persentase kontribusi suatu kategori terhadap keseluruhan penjualan.


Visualisasi ini memudahkan dalam mengidentifikasi kategori produk yang memiliki peran paling dominan dalam menghasilkan pendapatan, sehingga dapat dijadikan dasar dalam pengambilan keputusan terkait strategi penjualan dan pengelolaan produk.

3. Grafik Top 10 Produk dengan Penjualan Tertinggi

```
# Mengambil 10 produk teratas
top_10 = master_df.groupby('product name')['sales'].sum().sort_values(ascending=False).head(10).reset_index()

plt.figure(figsize=(12, 7))
sns.barplot(
    data=top_10,
    x='sales',
    y='product name',
    hue='product name',
    palette='mako',
    legend=False
)
plt.title('10 Produk Teratas Berdasarkan Nilai Penjualan', fontsize=14)
plt.xlabel('Total Penjualan')
plt.ylabel('Nama Produk')
plt.show()
```

Gambar 2. 22 Source code top 10 produk dengan penjualan tertinggi



Gambar 2. 23 Visualisasi top 10 produk dengan penjualan tertinggi

Pada visualisasi ini dilakukan analisis terhadap produk dengan performa terbaik berdasarkan total penjualan. Data dikelompokkan berdasarkan *product name*, kemudian dihitung total *sales* untuk masing-masing produk.

Selanjutnya, dipilih 10 produk dengan nilai penjualan tertinggi menggunakan fungsi *sorting* dan *head()*. Hasil tersebut divisualisasikan dalam bentuk diagram batang (bar chart).

Grafik ini memberikan gambaran yang jelas mengenai produk-produk unggulan yang memberikan kontribusi terbesar terhadap penjualan, sehingga dapat membantu perusahaan dalam menentukan prioritas stok dan strategi pemasaran.

4. Grafik Distribusi Penjualan Berdasarkan Kategori dan Segmen Pelanggan


```
# Region menjadi Category
plt.figure(figsize=(12, 6))

sns.barplot(
    data=master_df,
    x='category',
    y='sales',
    hue='segment',
    estimator=sum,
    errorbar=None,
    palette='mako'
)

plt.title('Distribusi Penjualan per Kategori Berdasarkan Segmen Pelanggan', fontsize=14)
plt.xlabel('Kategori Produk', fontsize=12)
plt.ylabel('Total Penjualan', fontsize=12)
plt.legend(title='Segmen Pelanggan')
plt.grid(axis='y', linestyle='--', alpha=0.3)

plt.show()
```

Gambar 2. 24 Source code distribusi penjualan kategori dan segmen pelanggan



Gambar 2. 25 Visualisasi distribusi penjualan kategori dan segmen pelanggan

Visualisasi ini bertujuan untuk menganalisis hubungan antara kategori produk dan segmen pelanggan terhadap total penjualan. Data divisualisasikan menggunakan diagram batang berkelompok (grouped bar chart) dengan kategori produk sebagai sumbu horizontal dan nilai penjualan sebagai sumbu vertikal.

Selain itu, digunakan parameter *hue* untuk membedakan segmen pelanggan (misalnya *consumer*, *corporate*, dan *home office*). Nilai penjualan dihitung menggunakan fungsi agregasi *sum*.

Visualisasi ini memungkinkan analisis yang lebih mendalam mengenai bagaimana masing-masing segmen pelanggan berkontribusi terhadap penjualan pada setiap kategori produk.

5. Grafik Distribusi Frekuensi Transaksi per Segmen Pelanggan


```
import plotly.express as px

# Menghitung jumlah unik Order ID untuk setiap segmen
segment_counts = master_df.groupby('segment')['order id'].nunique().reset_index()
segment_counts.columns = ['segment', 'total_orders']

fig = px.treemap(segment_counts,
                 path=['segment'],
                 values='total_orders',
                 title='Distribusi Frekuensi Transaksi per Segmen Pelanggan',
                 color='total_orders',
                 color_continuous_scale='GnBu')

fig.update_layout(margin=dict(t=50, l=25, r=25, b=25))
fig.show()
```

Gambar 2. 26 Source code distribusi frekuensi transaksi per segmen pelanggan



Gambar 2. 27 Visualisasi distribusi frekuensi transaksi per segmen pelanggan

Visualisasi terakhir bertujuan untuk menganalisis jumlah transaksi yang dilakukan oleh setiap segmen pelanggan. Data dihitung berdasarkan jumlah unik *order id* untuk masing-masing segmen menggunakan fungsi *nunique()*.

Hasilnya divisualisasikan menggunakan **treemap** dari library Plotly. Dalam treemap, ukuran setiap kotak merepresentasikan jumlah transaksi, sedangkan warna menunjukkan intensitas nilai.

Visualisasi ini memberikan gambaran mengenai segmen pelanggan yang paling aktif dalam melakukan transaksi, sehingga dapat digunakan untuk menentukan strategi pemasaran yang lebih tepat sasaran.

2.6 Analisis Hasil Akhir Data

Setelah proses implementasi database selesai, tahap berikutnya adalah melakukan analisis terhadap data yang telah tersusun dalam bentuk *star schema*. Analisis ini bertujuan

untuk mengekstraksi informasi yang bernilai dan relevan, sehingga dapat dimanfaatkan oleh manajemen retail dalam mendukung pengambilan keputusan strategis. Berdasarkan hasil pengolahan pada *Data Warehouse*, diperoleh beberapa temuan utama sebagai berikut:

2.6.1 Analisis Tren Penjualan Berdasarkan Waktu

Melalui pemanfaatan tabel *dim_date* yang terhubung dengan *fact_sales*, dapat dianalisis pola penjualan berdasarkan waktu, baik secara tahunan maupun bulanan.

Hasil analisis menunjukkan adanya tren musiman, di mana penjualan mengalami peningkatan signifikan pada kuartal keempat (Oktober–Desember). Kondisi ini kemungkinan dipengaruhi oleh momen libur akhir tahun serta berbagai program promosi dan festival belanja yang meningkatkan daya beli konsumen.

Di sisi lain, stabilitas penjualan pada awal tahun cenderung terjaga meskipun terdapat fluktuasi. Namun, pada pertengahan tahun (Mei–Juli), terlihat potensi penurunan volume transaksi. Oleh karena itu, perusahaan disarankan untuk menerapkan strategi promosi yang lebih agresif pada periode tersebut guna menjaga konsistensi penjualan.

2.6.2 Analisis Performa Produk dan Kategori

Dengan menggunakan tabel *dim_product*, perusahaan dapat mengidentifikasi kontribusi masing-masing produk dan kategori terhadap total pendapatan.

Dari hasil analisis, diketahui bahwa kategori Office Supplies memiliki volume transaksi tertinggi, yang menunjukkan tingginya frekuensi pembelian. Sementara itu, kategori Technology memberikan nilai penjualan per transaksi yang lebih besar, sehingga berkontribusi signifikan terhadap total pendapatan meskipun jumlah transaksinya tidak sebanyak kategori lainnya.

Berdasarkan temuan ini, strategi pengelolaan inventori dapat dioptimalkan. Produk dengan tingkat perputaran rendah (*low turnover*) sebaiknya diberikan promo atau diskon untuk menghindari penumpukan stok. Sebaliknya, produk dengan permintaan tinggi perlu dijaga ketersediaannya melalui pengelolaan *safety stock* agar tidak terjadi kekosongan barang.

2.6.3 Analisis Segmentasi dan Lokasi Pelanggan

Integrasi antara tabel *dim_customer* memungkinkan perusahaan untuk memahami distribusi pelanggan berdasarkan segmen pasar. Analisis dilakukan dengan membandingkan kontribusi penjualan dari masing-masing segmen pelanggan terhadap berbagai kategori produk.

Berdasarkan hasil visualisasi, diketahui bahwa segmen Consumer memberikan kontribusi penjualan terbesar dibandingkan segmen lainnya, diikuti oleh segmen Corporate dan Home Office. Hal ini menunjukkan bahwa pelanggan individu memiliki

tingkat aktivitas transaksi yang lebih tinggi.

Selain itu, terlihat bahwa setiap segmen memiliki kecenderungan berbeda dalam membeli kategori produk tertentu, sehingga perusahaan dapat menyesuaikan strategi pemasaran berdasarkan karakteristik masing-masing segmen pelanggan. Pendekatan ini dapat membantu meningkatkan efektivitas promosi serta meningkatkan loyalitas pelanggan.

2.6.4 Potensi Forecasting (Peramalan) Penjualan

Data historis yang telah terintegrasi dan bersih dalam Data Warehouse memberikan dasar yang kuat untuk melakukan proses forecasting di tahap selanjutnya. Dengan memanfaatkan metode statistik maupun machine learning, seperti ARIMA atau Linear Regression, perusahaan berpotensi menghasilkan prediksi penjualan yang lebih akurat.

Melalui analisis tren penjualan yang telah dilakukan, perusahaan dapat mengidentifikasi pola musiman yang dapat dijadikan dasar dalam peramalan. Beberapa manfaat yang dapat diperoleh dari proses ini antara lain adalah estimasi kebutuhan stok untuk periode mendatang serta penentuan target penjualan berdasarkan tren historis.

Dengan demikian, meskipun pada penelitian ini belum dilakukan implementasi model forecasting secara langsung, Data Warehouse yang dibangun telah siap digunakan untuk mendukung analisis prediktif di masa depan.

BAB III

PENUTUP

3.1 Kesimpulan

Berdasarkan hasil perancangan dan implementasi Data Warehouse pada dataset *Sales Forecasting Retail*, dapat disimpulkan bahwa pendekatan *star schema* berhasil diterapkan untuk mengorganisasi data transaksi menjadi struktur yang lebih terintegrasi dan mudah dianalisis. Proses ETL (*Extract, Transform, Load*) yang dilakukan mampu meningkatkan kualitas data melalui pembersihan data, penghapusan duplikasi, serta konversi tipe data sehingga data siap digunakan dalam analisis.

Implementasi tabel dimensi seperti *dim_date*, *dim_product*, *dim_customer*, dan *dim_location*, serta tabel fakta *fact_sales*, memungkinkan analisis multidimensi dilakukan secara efektif. Dari hasil analisis, ditemukan bahwa terdapat pola tren penjualan yang bersifat musiman, performa produk yang berbeda antar kategori, serta distribusi pelanggan yang bervariasi berdasarkan wilayah dan segmen.

Selain itu, Data Warehouse yang dibangun juga mampu mendukung proses *forecasting* penjualan dengan memanfaatkan data historis yang telah terstruktur. Hal ini menunjukkan bahwa sistem yang dirancang tidak hanya berguna untuk analisis deskriptif, tetapi juga memiliki potensi untuk analisis prediktif guna mendukung pengambilan keputusan bisnis yang lebih tepat.

3.2 Saran

Berdasarkan hasil penelitian yang telah dilakukan, terdapat beberapa saran yang dapat dipertimbangkan untuk pengembangan selanjutnya. Pertama, penggunaan metode *forecasting* dapat dikembangkan lebih lanjut dengan mengimplementasikan model yang lebih kompleks seperti ARIMA, Prophet, atau algoritma *machine learning* lainnya untuk meningkatkan akurasi prediksi.

1. Sistem Data Warehouse dapat dikembangkan dengan menggunakan DBMS yang lebih skalabel seperti MySQL atau PostgreSQL agar mampu menangani data dalam jumlah yang lebih besar dan mendukung penggunaan pada skala yang lebih luas.
2. Integrasi dengan tools Business Intelligence seperti Power BI atau Tableau dapat dilakukan untuk menghasilkan visualisasi data yang lebih interaktif dan mudah dipahami.
3. Penelitian selanjutnya dapat menambahkan variabel lain seperti promosi, diskon, atau kondisi ekonomi yang dapat memengaruhi penjualan, sehingga hasil analisis menjadi lebih lengkap.
4. Perlu dilakukan pembaruan data (*data updating*) secara berkala agar Data Warehouse

tetap relevan dan mampu memberikan informasi yang terbaru untuk pengambilan keputusan bisnis.

DAFTAR PUSTAKA

- Handika, I. P. S., & Santika, P. P. (2020). Perancangan data warehouse dan teknologi business intelligence untuk analisa penjualan pada perusahaan retail PT. ABC. *Rabit: Jurnal Teknologi dan Sistem Informasi*, 5(2), 76–85.
- Handika, I. P. S., Tama, G. B. A., & Krisnayanti, N. P. M. (2020). Penerapan teknologi data warehouse NoSQL dan business intelligence untuk analisa transaksi penjualan. *Jurnal RESISTOR (Rekayasa Sistem Komputer)*, 3(2), 120–127.
- Hartanto, R., Kirana, J. C., & Indra. (2025). Perancangan data warehouse menggunakan metode star schema dan ETL untuk menghasilkan laporan efektivitas proses rekrutmen kandidat. *Jurnal Pendidikan dan Teknologi Indonesia*, 5(12), 3658–3672.
- Putra, I. N. A. (2019). Optimasi proses ETL dengan metode heuristik untuk membangun data warehouse. *Jurnal Sains dan Teknologi*, 8(1), 35–43.
- Yulianto, A., & Firmansyah. (2024). Optimalisasi performa data warehouse dengan data mart. *REMIK: Riset dan E-Jurnal Manajemen Informatika Komputer*, 8(4).
- Gunawan, A., Iskandar, A., & Purba, O. S. M. (2022). Rancang bangun business intelligence untuk memantau data berbasis data warehouse. *Jurnal Ilmiah Komputasi*.
- Edhya, B. F. P. (2022). Business intelligence data marketing menggunakan metode Kimball dan ETL dengan Power BI. *Jurnal Kurawal*, 5(2), 87–97.
- Hartono, R. (2025). Real-time data integration dan modeling untuk kebutuhan business intelligence menggunakan pendekatan agile. *Jurnal Algoritma*, 22(1), 79–88.